



Groupe des écoles
nationales d'économie
et statistique



Machine Learning for Climate Risk

De l'humidité du sol à la reconnaissance CatNat

*Modélisation multi-échelles de la sécheresse en France à partir des
indices SWI*

Janvier 2026



PRESENTATEURS



Durel Valdes NZIALI TCHAMOU




Esthelle Paloma KUISSU CHEGAING

Superviseur



M. Antonio Ocello, Professeur à l'ENSAE

PLAN



- 1 Contexte, Intérêt, Méthodologie
- 2 Modélisation du SWI uniforme
- 3 Modélisation des indicateurs de sécheresse
- 4 Modélisation de la reconnaissance Cat-Nat
- 5 Impact et limite de notre analyse,

Contexte, Intérêt, Méthodologie (1/2)

La reconnaissance CatNat pour la sécheresse ne repose pas uniquement sur les dommages observés, mais sur un processus structuré.

1/ Episode de sécheresse



Les riverains
informent la
mairie



**2/ La commune
déclare les
dommages**



**3/ Evaluation
des indicateurs
par Météo
France**(SWI
Uniforme)



**4/ Commission
interministérielle**

Objectif : statué sur la
reconnaissance ou
non de la catastrophe




**5/ Publication de
l'arrêté CatNat**

Cet arrêté fait état de la
reconnaissance ou non
des communes ayant
déclaré leur catastrophe
et qui ont été étudié à
cette session


**En cas de
reconnaissance**

**L'assurance
intervient**



***Ceci justifie donc l'intérêt pour une compagnie d'assurance de savoir à l'avance
quelles communes est en mesure de faire une demande CatNat qui sera
reconnue. Le but est de suffisamment se provisionner face à ce risque à l'échelle
de la France***

Contexte, Intérêt, Méthodologie (2/2)



- **Explosion du nombre de demande,**
- **taux d'acceptation croissante dans le temps**



Pas qu'une simple crainte, un risque réel pour une assurance mal préparée

Objectif : Mieux prévoir, mieux assurer

- Afin de bien réagir face à cette situation la compagnie d'assurance a besoin de pouvoir répondre à la question suivante : si une commune fait une demande est ce que je suis capable de savoir si cette demande sera acceptée? Sachant bien sur qu'***il ne sait pas en avance si une commune fera une demande ou pas***
- En effet : ce qui influence le fait de faire une demande ou non n'est pas toujours la simple présence de la sécheresse Par exemple : Pour une question de réputation une commune peut décider de ne pas faire de demande, et des **aspects non quantifiables** comme celle-ci sont nombreuses

***D'où l'importance de :
comprendre les indicateurs
qui caractérisent la
sécheresse***



***Nouvelle cible : Prédire
la sécheresse***



On distingue plusieurs caractérisations de la sécheresse :

- Quantile sur 5%
- Quantile à 25 %
- Règle officielle.

Basée sur le l'indicateur du d'humidité du sol le **SWI**
Uniforme

Une analyse de ces indicateurs nous montre une
sécheresse historique durant le troisième trimestre
(Marqué par la grande partie de l'été)




Cependant pour prédire la sécheresse à un
instant donnée, il faut avoir des informations sur
l'humidité du sol à ce moment précis au travers
du SWI Uniforme, mais cette information n'est
pas toujours disponible avant la fin de l'année
correspondante.

Ind_Q5

Ind_Q25

Ind_Officiel



01.



Nouvelle cible : Prédire le SWI Uniforme à partir des informations passées dispositions


Modélisation du SWI Uniforme

✓ Présentation des indicateurs qui influence l'humidité le sol




argileux = *capacité de rétention d'eau élevée* Mais *difficulté d'infiltration*

0.0 1.4 2.1 10.0
Teneur en argile (%) — 3 classes



Quantité d'eau moyenne ajoutée par an (*Pluie – Evapotranspiration*)

ClimatScore_std (sec ← 0 → humide)



Evolution temporelle du SWI uniforme nous montre que la sécheresse est de plus en plus présente en France

De plus le SWI uniforme dépend fortement du SWI, En effet on a une corrélation d'au moins 0,96 par année

2001 — SWI uniforme

2011 — SWI uniforme

2022 — SWI uniforme

SWI uniforme annuel

Le **SWI Uniforme** est une information qui n'est disponible que mensuellement et au plus deux fois pendant l'année en cours. Alors le but sera de prédire le vecteur de SWI uniforme mensuelle en se servant de son historique mensuelle et de l'historique mensuelle du SWI et des autres variables auxiliaires telles que le pourcentage d'argile, l'évapotranspiration et bien d'autres caractéristiques météo mensuelle disponibles.

De plus ce forecast est fait à l'échelle de toute la France donc une prise en compte de la corrélation spatiale est un facteur très important pour la cohérence du travail

STRUCTURE DES DONNEES

Notre jeu de données est sous forme de **panel de plus 25 ans** où pour chaque point de la grille Safran Nous avons des informations mensuelles sur le SWI Uniforme, Swi et d'autres caractéristiques utiles en plus de cela nous savons quelles sont ses coordonnées et dans quelle commune il appartient (Ce qui est utile pour faire une interpolation spatiale)


Pour l'entrainement : jusqu'à 2019


Pour l'évaluation : 2020-2024

DEMARCHE

- 25% Choisir une famille de modèles (XGBOOST etc,)
- 50% Déterminer le retard optimale (h_1^* h_2^*) pour le swi uniforme et pour le Swi (Prédire optimalement swi_{unif_t} , avec $(swi_{unif_{t-1}}, \dots, swi_{unif_{t-h_1^*}}, swi_{t-1}, \dots, swi_{t-h_2^*}, X_t)$ avec $y_t \in R^{12}$
- 75% Optimiser le modèle
- 100% Faire une correction spatiale (Le Kriging sera priorisé)

Modèle	MAE	RMSE	h1*, h2*
RL(ridge)	0,138	0,181	(6,3)
XGBOOST	0,134	0,177	(1,5)
RandomForest	0,135	0,173	(5,4)
Neural Network	0,125	0,171	(2,4)





Quelques résultats



Le modèle **sous-estime** le SWI uniforme Dans les régions de **Grand EST , Auvergne-Rhone-Alpes et Bourgogne**, Certainement dû aux Sols plus homogènes, souvent moins argileux. **Avantagées en cas de décision CatNat**



Le modèle **surestime** le SWI uniforme Dans les zones: **Sud-Est, Sud-Ouest méditerranéen, Corse**. Site caractérisé par leur forte teneur en Argile et aussi par une grande hétérogénéité entre le SWI uniforme et le SWI et entre les caractéristiques du sols. **Désavantagées en cas de décision CatNat**



Le modèle **estime bien** le SWI uniforme Dans les zones de : **Ouest et Nord-Ouest (Bretagne, Normandie)**. Régions climatiquement plus stables, sols peu argileux



La standardisation par le **SWI uniforme**, bien que nécessaire, peut **masquer des vulnérabilités locales**


Focus sur le Grand Est et la Bretagne

Bien que le modèle réagit plutôt bien en termes d'erreur.
Et de prédiction globale.


On distingue clairement deux zones:

- **Cercle Rouge** (Grand Est) où les communes sont fortement avantagées.
- **Cercle noir** (Bretagne) où celles-ci sont défavorisés si l'on devrait faire prendre une décision CatNat

Erreur moyenne interpolée (2020-2024)
Grand Est (code région 44)



Erreur moyenne interpolée (2020-2024)
Bretagne (code région 53)



Modélisation de la sécheresse

A ce stade nous avons une bonne connaissances SWI Uniforme, nous avons donc le nécessaire pour prédire si une zone sera exposée à une situation de sécheresse ou non, l'on modélise trois indicateurs différents pour mieux apprécier le phénomène de sécheresse

MODELISATION

Etant donné un indicateur à une année fixe, l'on prédira un vecteur de taille 4 qui dira si durant un trimestre notre zone est en situation de sécheresse ou pas en fonction des vecteurs de ses caractéristiques donc les composantes sont à l'échelle trimestrielle tel que le swi uniforme, des indices hydriques court et moyen terme etc...

Une correction spatiale est prise en compte pour la généralisation

STRUCTURE DES DONNEES

Notre jeu de données a la structure similaire de **panel de plus 25 ans**, à la différence que nous avons cette fois les différents indicateurs de sécheresse trimestrielle,

Pour l'entraînement : jusqu'à 2019


Pour l'évaluation : 2020-2024

✓ Performance des modèles

	Modèle	Macro-F1	Macro-Recall	Macro-Precision	HammingAcc
Ind Q 5%	Multi-HGB	0,743	0,716	0,774	0,96 (best)
	Multi-LogReg	0,652	0,930	0,516	0,93
	Chain-LogReg	0,651	0,923	0,515	0,92
Ind Q 25 %	Multi-HGB	0,898	0,906	0,829	0,94 (best)
	Multi-LogReg	0,87	0,917	0,83	0,92
	Chain-LogReg	0,87	0,917	0,829	0,92
Ind officiel	Multi-HGB	0,649	0,684	0,63	0,96 (best)
	Multi-LogReg	0,502	0,92	0,352	0,91
	Chain-LogReg	0,49	0,916	0,341	0,91

✓ Contribution des variables au meilleur modèle

Type de Variables	Q5(%)	Q25(%)	Officielle(%)
Indices hydriques Court terme	68,2	73,3	56,2
Indices hydriques Long terme	26,7	19,3	15,8
Flux hydrologiques	1,7	3,2	22,1
Persistance (Lag)	4,2	1,8	7,8
Variables spatiales	0,5	0,7	2



Quelques analyses

- ✓ Les **scores Macro-F1 élevés sur Q25** confirment que la sécheresse modérée est plus prévisible que la sécheresse extrême.
- ✓ Les performances plus faibles sur l'indicateur officiel montrent que la **décision administrative est plus difficile à prédire que le phénomène physique**.
- ✓ La forte contribution des **indices hydriques de court terme** souligne que la reconnaissance repose principalement sur la dynamique récente de l'humidité des sols.

Quelques résultats

Ces cartes montrent que le modèle reproduit correctement la géographie de la sécheresse en France, en particulier pour les événements modérés à sévères (Q5 à Q25), qui sont les plus fréquents et les plus pertinents d'un point de vue assurantiel.

Les sécheresses très extrêmes restent plus difficiles à capter localement, ce qui est attendu compte tenu de leur rareté. En revanche, la comparaison avec l'indicateur officiel met en évidence des effets de seuil liés à la décision administrative, qui peuvent créer des disparités territoriales.

Pour les assureurs, cette modélisation constitue un outil clé d'anticipation de l'exposition CatNat, plusieurs mois avant la publication officielle des arrêtés

Modélisation de la reconnaissance

Nous venons de rendre une compagnie d'assurance capable d'anticiper si une commune effectuera une demande ou pas. Maintenant, l'objectif est de répondre à notre question première : **si une demande est faite sera-t-elle reconnue ou non?** Et pour répondre à cette question nous modéliserons un système de classification (reconnu(1)/non reconnu(0)).

MODELISATION

✓ **Modèle optimisé**

STRUCTURE DES DONNEES

Notre jeu de données est constitué de communes avec une structure particulière ce **n'est pas un vrai panel**. En effet chaque commune a le choix de faire une demande ou non, Alors pour une année on n'a pas un nombre fixe de commune qui effectue la demande et rien ne nous dit qu'une commune effectuera une demande cette année en particulier ou pas, cette particularité constitue une des principales difficultés de notre travail.


Pour l'entrainement : jusqu'à 2022

Pour l'évaluation : 2023-2024

Notre objectif est de mettre en place un modèle qui saura bien généralisé sur les communes qu'il connaît et sur des communes qu'il n'a jamais observé, Surtout prendre en compte le biais humain apporté dans la prise de décision CatNat,

A cet effet plusieurs modèle de classification ont été testé

Une correction spatiale est prise en compte pour la généralisation



✓ **Performance des modèles : Meilleur variogramme = gaussienne**

Modèle	Weighted-F1	Weighted-Recall	Weighted-Précision	Accuracy
RandomForest	0,77	0,74	0,85	0,74
Logistique	0,80	0,78	0,87	0,78
SVM	0,73	0,71	0,84	0,71
Multi-HGB	0,74	0,71	0,81	0,71

Classe	Précision	Recall	F1-Score	Support
0	0,97	0,77	0,86	4715
1	0,49	0,89	0,63	1183
Macro avg	0,73	0,83	0,75	Accuracy: 0,79
Weighted avg	0,87	0,79	0,81	

Le modèle retenu discrimine efficacement les communes non reconnues (classe 0), tout en captant une large part des communes reconnues (classe 1), au prix d'une précision plus faible sur les événements positifs, ce qui en fait un outil pertinent d'anticipation du risque CatNat mais non un substitut à la décision administrative.

Seuils de contrôles

Classique

0,5




Reconnaissance prédite ($p_corr \geq 0.5$)
(dernière apparition)

Optimal Visuel

0,7605

Reconnaissance prédite ($p_corr \geq 0.7605$)
(dernière apparition)

Reconnaissance réelle
(dernière apparition)




Statut de la commune
● Reconnu ● Non reconnu ● Commune non présente

Les Cercles noirs : nous montrent des Zones que le modèle ne parvient pas à capter les facteurs qui influence la reconnaissance




Merci


ANNEXE






ANNEXE



ANNEXE




ANNEXE




ANNEXE

Évolution de la sécheresse (2000-2024)
OFF, Q5, Q25 par région — pentes + significativité (✓ : $p < 0,05$)




ANNEXE

Climat (Pluie - ETP) vs Sécheresse Durable OFF
Couleur = Argile | Taille = Sécheresse modérée Q25



Climat (Pluie - ETP) vs Sécheresse Durable Q5
Couleur = Argile | Taille = Sécheresse modérée Q25




✓ **Intuition Globale dans la construction des modèles**

- Considerons un problème de calibration
$$y_t = f(x_t, \theta) \text{ où } f(., \theta) \text{ est obtenue avec les méthodes de ML}$$
- Une fois f connue (par exemple XGBOOST) une correction spatiale est faite sur chaque année des données d'entraînement et une agrégation moyenne est retenue pour la généralisation sur les nouvelles données.

✓ **Cas concret de la correction spatiale : démarche pour le SWI**

- Une fois f calibré, alors pour chaque mois on construit le variogramme avec la meilleur concordance avec les données parmi les modèles gaussian, spherical, exponential, power, hole-effect. Ensuite on construit le variogramme moyen le plus adapté en se servant de la WLS comme métrique.
- Une fois que c'est fait on corrige les prédictions (On a donc 12 variogrammes pour les 12 mois correspondants)
- De plus afin de représenter correctement les prédictions on interpole spatialement simplement les prédictions pour des communes dont on ne dispose pas d'informations,

ANNEXE



Merci de votre attention